LAPORAN PROJECT PEMROSESAN TEKS

Dari Teks Mentah ke Representasi Siap Analisis: Jawaban dan Ulasan Skincare dan Kosmetik

Disusun oleh: Citra Fanysa

NIM: 25031554015

Program Studi: S1 Sains Data

Mata Kuliah: Pemrosesan Teks

Tahun Akademik: 2026/2027

Universitas Negeri Surabaya 2026

RINGKASAN PENGERJAAN

Laporan ini mendokumentasikan pipeline pemrosesan teks pada dua korpus skincare dan kosmetik berbahasa Indonesia: Dataset B (jawaban Quora, 354 baris, 352 terpakai) sebagai korpus utama, dan Dataset A (komentar bergaya Lazada, 200 baris) sebagai korpus pembanding. Tahapan yang dijalankan adalah case folding, cleaning, tokenisasi, penghapusan stopword, stemming (Sastrawi), representasi TF-IDF, pengukuran kemiripan dengan cosine similarity, dan pengelompokan dengan K-Means.

Pada Dataset B, jumlah token turun dari 12.555 (pemisahan spasi pada teks mentah) menjadi 9.382 setelah seluruh tahap, dan kosakata unik turun dari 2.983 menjadi 2.311. Matriks TF-IDF berukuran 352 x 950 dengan 98,0% elemen nol. Kemiripan antardokumen umumnya rendah (median 0,013; 45,9% pasangan bernilai 0), dan silhouette score K-Means hanya 0,004 sampai 0,011, sehingga pengelompokan tidak menunjukkan struktur yang tegas.

Temuan yang paling berpengaruh. Stemmer dan daftar stopword Sastrawi tidak menangani bahasa gaul. Kata seperti "yg", "pake", dan "ga" tetap muncul di antara kata paling sering setelah stopword dibuang, dan satu klaster pada K-Means (k = 8) terbentuk karena gaya bahasa, bukan topik. Selain itu, Dataset A dibangkitkan program dari hanya 10 komentar unik, sehingga hasil kemiripan dan klasternya mencerminkan data buatan, bukan opini konsumen.

1. PENDAHULUAN DAN RENCANA PEMROSESAN TEKS

1.1 Pertanyaan proyek

Bagaimana teks jawaban dan ulasan skincare berbahasa Indonesia diproses dari bentuk mentah menjadi representasi numerik (TF-IDF), dan seberapa baik representasi tersebut menangkap kemiripan antarteks serta kelompok topik?

1.2 Kebutuhan data dan unit dokumen

Kebutuhan	Variabel	Kegunaan
Teks jawaban	jawaban_bersih (Dataset B)	Korpus utama untuk seluruh tahap pipeline.
Konteks pertanyaan	pertanyaan_bersih (Dataset B)	Menilai apakah dua jawaban mirip karena menjawab pertanyaan yang sama.

Teks komentar	komentar (Dataset A)	Korpus pembanding untuk menguji pipeline pada teks buatan.
Label aturan	kategori_komentar (Dataset A)	Pembanding untuk membaca hasil klaster.

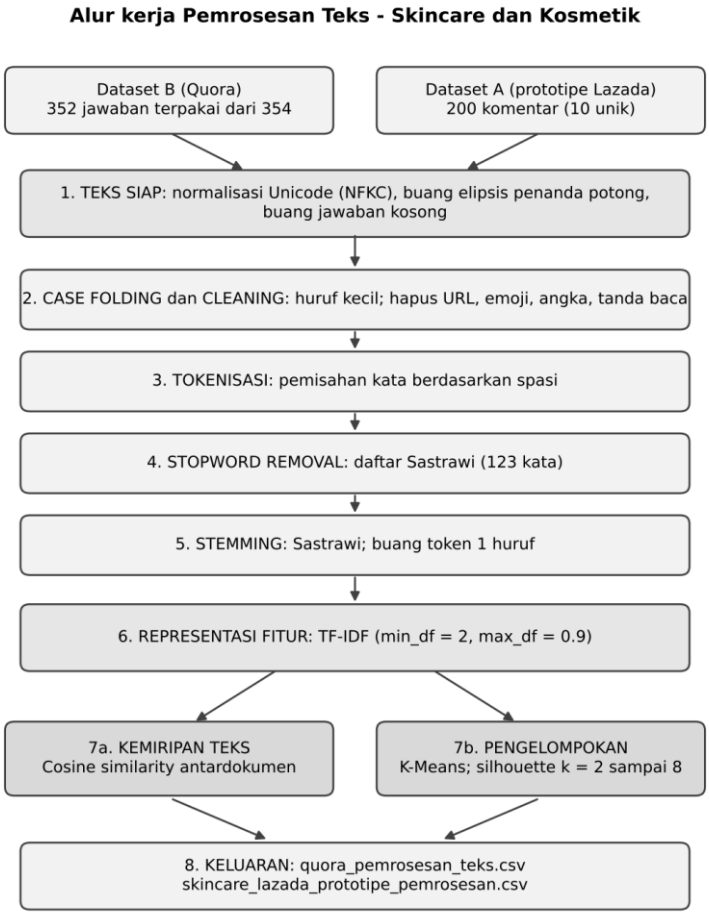
Satuan dokumen pada Dataset B adalah satu jawaban, dan pada Dataset A adalah satu komentar. Satu pertanyaan Quora dapat memiliki beberapa jawaban, sehingga beberapa dokumen berasal dari pertanyaan yang sama.

1.3 Alur kerja

Alur yang dijalankan: (1) teks siap, yaitu normalisasi Unicode dan pembuangan elipsis penanda potong dari hasil pembersihan sebelumnya; (2) case folding dan cleaning; (3) tokenisasi; (4) penghapusan stopword; (5) stemming; (6) representasi fitur dengan TF-IDF; (7) kemiripan teks dengan cosine similarity dan pengelompokan dengan K-Means; (8) penyimpanan hasil ke CSV.

Stopword dan stemmer berasal dari pustaka Sastrawi. TF-IDF, cosine similarity, K-Means, dan silhouette score berasal dari scikit-learn.

1.4 Alur tahapan pemrosesan teks



Gambar 1. Alur tahapan pemrosesan teks untuk Dataset A dan Dataset B.

2. INVENTARISASI KORPUS

Terdapat dua korpus yang diproses. Tiga berkas lain yang berlabel "lazada" merupakan salinan Dataset B sehingga tidak diproses terpisah.

Korpus	**Format/struktur**	**Satuan dokumen**	**Pemakaian terverifikasi**
Dataset B (Quora)	CSV, JSON, XLSX; kolom: QuestionText, AuthorName, AnswerSnippet	Satu jawaban	Dipakai; 354 baris, 352 dipakai setelah 2 jawaban kosong dikeluarkan
Dataset A (prototipe Lazada)	XLSX; kolom: No, Merek/Brand, Nama Produk,	Satu komentar	Dipakai; 200 baris, hanya 10 komentar unik

	Harga (Rp), Komentar Konsumen		
Berkas berlabel "lazada"	CSV, JSON, XLSX; isi sama dengan Dataset B	Satu jawaban	Tidak dipakai terpisah
Daftar stopword	Sastrawi (StopWordRemoverFactory)	Kata	123 kata

2.1 Karakteristik teks

Dataset B adalah teks nyata berbahasa Indonesia yang informal: banyak singkatan dan bahasa gaul, sebagian jawaban bercampur istilah Inggris, 45 jawaban memuat emoji, dan 7 jawaban memuat URL. Kolom AnswerSnippet adalah potongan jawaban, dan 240 dari 354 jawaban (67,8%) terpotong, sehingga dokumen yang diproses bukan jawaban utuh. Rata-rata panjang dokumen setelah seluruh tahap adalah 26,7 token.

Dataset A berisi kalimat yang rapi dan seragam. Rata-rata panjang dokumen setelah seluruh tahap hanya 9,8 token, dan kosakata uniknya hanya 74 kata.

2.2 Catatan inventaris

Kedua korpus tidak memiliki tanggal, URL sumber, rating, atau ID dokumen. Karena itu penelusuran dokumen ke sumber asli dan analisis perubahan topik dari waktu ke waktu tidak dapat dilakukan. Dataset A dibangkitkan oleh program (random.seed(42)), bukan hasil pengambilan data langsung dari Lazada.

3. PRA-PEMROSESAN TEKS

3.1 Case folding dan cleaning

Seluruh teks diubah menjadi huruf kecil. Cleaning menghapus URL, emoji, angka, dan tanda baca dengan ekspresi reguler [^a-z\s], lalu merapikan spasi. Pada Dataset B, jumlah token dari pemisahan spasi pada teks mentah adalah 12.555 dan menjadi 12.315 setelah cleaning. Pada Dataset A, jumlah token justru naik dari 2.538 menjadi 2.558 karena tanda hubung memecah kata ulang seperti "kecil-kecil" menjadi dua token.

3.2 Tokenisasi dan penghapusan stopword

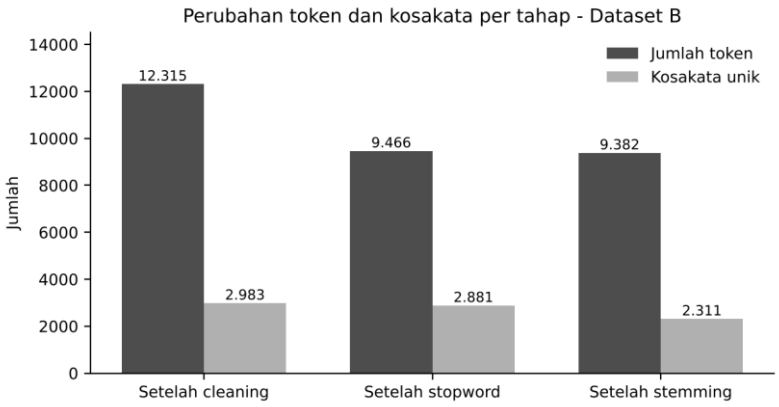
Tokenisasi dilakukan dengan memisahkan teks berdasarkan spasi. Penghapusan stopword memakai daftar Sastrawi (123 kata). Pada Dataset B, tahap ini membuang 2.849 token (23,1%) dan kosakata turun dari 2.983 menjadi 2.881.

3.3 Stemming

Stemming memakai stemmer Sastrawi, lalu token satu huruf dibuang. Contoh hasil yang tepat: "kulitnya" menjadi "kulit", "kerutan" menjadi "kerut", "mencerahkan" menjadi "cerah", "pemakaian" menjadi "pakai", dan "terpercaya" menjadi "percaya". Contoh yang tidak berubah: "melembabkan" dan "rekomendasi". Pada Dataset B, 28,0% jenis kata unik berubah, dan kosakata turun dari 2.881 menjadi 2.311.

3.4 Ringkasan per tahap

Tahap	Token B	Kosakata B	Token A	Kosakata A
Setelah case folding dan cleaning	12.315	2.983	2.558	90
Setelah penghapusan stopword	9.466	2.881	1.964	78
Setelah stemming	9.382	2.311	1.964	74



Gambar 2. Perubahan jumlah token dan kosakata unik per tahap pada Dataset B.

3.5 Masalah bahasa gaul dan tokenisasi

Daftar stopword dan stemmer Sastrawi disusun untuk bahasa baku. Pada 352 dokumen Dataset B, 15 bentuk gaul yang saya periksa muncul 384 kali setelah cleaning, antara lain "yg" (95

kali), "aja" (45 kali), "gak" (43 kali), "sih" (40 kali), dan "udah" (39 kali). Setelah stopword dibuang, "yg" (95), "pake" (89), dan "ga" (57) masih termasuk kata yang paling sering muncul.

Akibatnya, kata yang sama terpecah menjadi dua bentuk, misalnya "pake" dan "pakai", atau "kalo" dan "kalau". Tokenisasi berbasis spasi juga memecah istilah dua kata: "make up" menjadi "make" dan "up". Kedua masalah ini memengaruhi TF-IDF dan klaster pada bagian berikutnya. Perbaikan yang diusulkan adalah kamus normalisasi bahasa gaul sebelum stemming dan penggabungan istilah dua kata.

4. REPRESENTASI FITUR (TF-IDF)

4.1 Konfigurasi

TF-IDF dibangun dengan TfidfVectorizer (min_df = 2, max_df = 0.9) pada 352 dokumen Dataset B. Kata yang muncul di kurang dari 2 dokumen dibuang karena tidak berguna untuk membandingkan dokumen, dan kata yang muncul di lebih dari 90% dokumen dibuang karena tidak membedakan. Kosakata sebelum penyaringan adalah 2.311 kata, dan sesudahnya 950 fitur. Matriks akhir berukuran 352 x 950 dengan 6.557 elemen tidak nol (98,0% nol).

4.2 Kata dengan bobot rata-rata tertinggi

Peringkat	Kata	Rata-rata TF-IDF
1	pakai	0,0427
2	kulit	0,0399
3	pake	0,0322
4	wajah	0,0305
5	yg	0,0304
6	aku	0,0278
7	skincare	0,0256
8	lebih	0,0247
9	jadi	0,0238
10	kalau	0,0235

Kata teratas (pakai, kulit, pake, wajah, yg, aku) didominasi kata umum dan bentuk gaul, bukan kata yang menandai topik tertentu. Hal ini sejalan dengan temuan pada bagian 3.5 dan menunjukkan bahwa daftar stopword perlu diperluas.

5. KEMIRIPAN TEKS (COSINE SIMILARITY)

5.1 Distribusi kemiripan

Cosine similarity dihitung antara seluruh pasangan dokumen pada Dataset B (61.776 pasangan).

Ukuran	Nilai
Rata-rata	0,0317
Median	0,0130
Persentil ke-95	0,1215
Maksimum	0,7936
Pasangan bernilai 0	45,9%
Pasangan dengan skor > 0,3	174
Pasangan dengan skor > 0,5	15

Sebagian besar pasangan tidak berbagi kata bermakna, sehingga skornya sangat rendah. Hanya sedikit pasangan yang tergolong mirip.

5.2 Pasangan paling mirip

Peringkat	Skor	Pertanyaan sama	Pertanyaan (potongan)
1	0,7936	Tidak	Bagaimana cara mengembalikan warna kulit asli kita seperti bawaan lahi / Seperti apa perbandingan penampilanmu mengunakan make-up dan tanpa mak
2	0,6896	Ya	Seperti apa perbandingan penampilanmu mengunakan make-up dan tanpa mak
3	0,6502	Tidak	Seperti apa perbandingan penampilanmu mengunakan make-up dan tanpa mak / Bagaimana cara mengembalikan warna kulit asli kita seperti bawaan lahi
4	0,6118	Ya	Apakah parfum KW memiliki wangi yang sama dengan parfum aslinya?

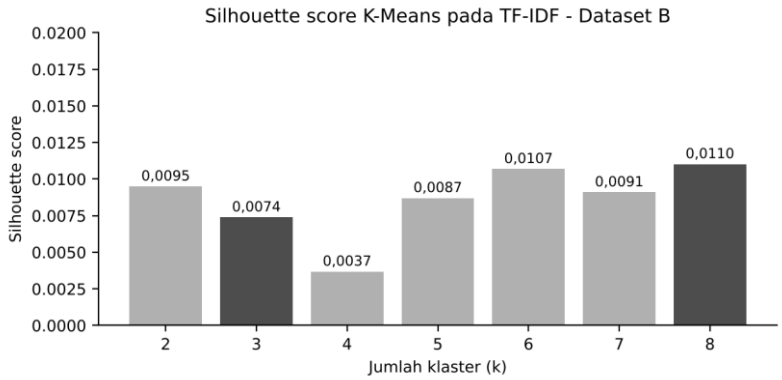
5	0,6069	Ya	Seperti apa perbandingan penampilanmu mengunakan make-up dan tanpa mak

Pasangan teratas (skor 0,794) berasal dari dua pertanyaan berbeda, dan kedua jawabannya hanya beberapa kata pendek yang sama-sama memuat "make up". Jadi skor tinggi di sini muncul karena teksnya sangat pendek dan berbagi kata, bukan karena maknanya setara. Dari 15 pasangan dengan skor di atas 0,5, hanya 5 yang menjawab pertanyaan yang sama; dari 174 pasangan di atas 0,3, hanya 24. Dengan demikian cosine similarity pada TF-IDF di korpus ini tidak dapat dipakai sebagai penanda jawaban yang sepadan tanpa memeriksa panjang teks.

6. PENGELOMPOKAN TEKS (K-MEANS)

6.1 Pemilihan jumlah klaster

K-Means dijalankan pada matriks TF-IDF Dataset B dengan n_init = 10 dan random_state = 42 untuk k = 2 sampai 8. Kualitas klaster dinilai dengan silhouette score.



Gambar 3. Silhouette score K-Means untuk k = 2 sampai 8 pada Dataset B.

Seluruh nilai silhouette berada antara 0,0037 dan 0,0110, sangat dekat dengan 0, yang berarti klaster saling tumpang tindih dan tidak terpisah tegas. Nilai tertinggi ada pada k = 8 (0,0110), tetapi selisihnya dengan k = 3 (0,0074) kecil, sehingga pilihan k = 8 bukan pemisahan yang kuat. Silhouette yang rendah umum pada teks pendek berdimensi tinggi [Kepercayaan sedang].

6.2 Hasil klaster (k = 8)

Klaster	Jumlah	Kata teratas	Tafsiran (subjektif)
0	27	makan, minum, banyak, sehat, sayur, buah, air, olahraga	Makanan dan gaya hidup sehat

1	94	kulit, serum, minyak, skincare, cocok, produk, bahan, cari	Skincare dan serum
2	39	aku, kalau, pakai, makeup, gak, jam, malam, foto	Makeup dan kebiasaan harian
3	22	pakai, masker, sekali, baik, muka, cuci, cetaphil, hari	Masker dan cuci muka
4	82	pake, yg, ga, kalo, aja, putih, kulit, sih	Gaya bahasa informal (bukan topik)
5	29	parfum, aroma, banyak, jadi, lebih, buat, terlalu, harga	Parfum
6	43	wajah, kulit, bersih, awat, lebih, orang, lihat, jadi	Kulit bersih dan awet muda
7	16	up, make, rb, soal, pede, jago, tidur, tone	Artefak tokenisasi "make up"

Sebagian klaster dapat ditafsirkan sebagai topik: makanan dan gaya hidup (27 dokumen), skincare/serum (94), parfum (29), dan masker/cuci muka (22). Dua klaster bermasalah: klaster 4 (82 dokumen) dibentuk oleh kata gaul (pake, yg, ga, kalo, aja, sih), dan klaster 7 (16 dokumen) dibentuk oleh pemisahan "make up". Tafsiran topik ini hasil pembacaan saya atas kata teratas dan belum diuji pada sampel dokumen.

Sebagai pembanding, k = 3 menghasilkan klaster berukuran 157, 81, 114 dengan silhouette 0,0074; klaster tersebut didominasi kata umum (pakai, kulit, wajah, aku, kalau), sehingga kurang informatif dibanding k = 8.

7. HASIL ANALISIS DAN PEMBAHASAN

7.1 Dataset B

Pipeline berhasil menurunkan 12.315 token hasil cleaning menjadi 9.382 token bermakna dan merepresentasikan 352 dokumen dalam 950 fitur. Namun kualitas representasinya dibatasi tiga hal: bahasa gaul yang tidak ditangani, tokenisasi yang memecah istilah dua kata, dan teks yang terpotong. Pengelompokan menghasilkan beberapa topik yang masuk akal (makanan, skincare, parfum), tetapi dengan silhouette mendekati 0 dan dua klaster yang terbentuk karena gaya bahasa dan artefak tokenisasi.

7.2 Dataset A

Pipeline yang sama dijalankan pada 200 komentar Dataset A: token turun dari 2.558 menjadi 1.964, kosakata dari 90 menjadi 74, dan matriks TF-IDF berukuran 200 x 74. Pada 10 komentar unik, kemiripan tertinggi hanya 0,218 dan 20 dari 45 pasangan bernilai 0.

K-Means (k = 3) menghasilkan klaster berukuran 41, 101, dan 58 dengan silhouette 0,310. Tidak ada satu pun dari 10 komentar unik yang terpecah ke dua klaster (0 komentar terpecah), dan pada k = 10 silhouette mencapai 1,000, artinya klaster identik dengan kalimat-kalimat yang diulang. Silhouette yang tinggi di sini bukan bukti struktur topik, melainkan akibat data yang hanya terdiri dari 10 kalimat berulang.

7.3 Kesimpulan dan keterbatasan

Kesimpulan: pipeline pemrosesan teks berjalan pada kedua korpus dan menghasilkan CSV yang siap dipakai, tetapi hanya Dataset B yang layak untuk menilai perilaku teks nyata. Representasi TF-IDF pada korpus ini menangkap kata umum dan gaya bahasa lebih kuat daripada topik, sehingga kemiripan dan klaster perlu dibaca dengan hati-hati.

Keterbatasan yang tercatat:

- Dataset A dibangkitkan program dan hanya memuat 10 komentar unik; hasilnya tidak mewakili konsumen sungguhan.
- Dataset B terpotong pada 240 dari 354 jawaban, dan dokumen pendek memicu skor cosine yang tinggi secara semu.
- Sastrawi tidak menangani bahasa gaul; belum ada kamus normalisasi.
- Tokenisasi berbasis spasi memecah istilah dua kata seperti "make up".
- Pemilihan k hanya memakai silhouette, dan tafsiran klaster bersifat subjektif serta belum divalidasi.
- Tidak ada label topik atau sentimen yang benar sebagai pembanding untuk menilai klaster.